

# Risk Averse Dynamic Programming

Andrés Ferragut

Universidad ORT Uruguay

UTE 2020

Medidas de riesgo

Programación dinámica de riesgo coherente

SDDP con medidas de riesgo

Ejemplo

Se considera un espacio de probabilidad  $(\Omega, \mathcal{F}, P)$  en el cual están definidas variables aleatorias  $X : \Omega \rightarrow \mathbb{R}$ . Sea  $\mathcal{X}$  el espacio vectorial  $L^p = \{X : E[|X|^p] < \infty\}$  con  $p \geq 1$ .

## Definición: Función de Riesgo

Una **función de riesgo** es un funcional  $\rho : \mathcal{X} \rightarrow \mathbb{R}$  que asigna a cada variable aleatoria un valor de riesgo. Asumimos que  $X$  es un costo por lo que valores altos de  $X$  implican mayor riesgo.

## Definición: Riesgo Coherente

Una función de riesgo se denomina **coherente** si verifica:

A1 **Convexidad:**  $\rho(\lambda X + (1 - \lambda)Y) \leq \lambda \rho(X) + (1 - \lambda)\rho(Y)$ ,  $\forall X, Y \in \mathcal{X}$ ,  $\lambda \in [0, 1]$ .

A2 **Monotonía:** Para todo  $X, Y \in \mathcal{X}$ ,  $X \leq Y \Rightarrow \rho(X) \leq \rho(Y)$ .

A3 **Equivariancia traslacional:** Para todo  $X \in \mathcal{X}$ ,  $c \in \mathbb{R}$ ,  $\rho(X + c) = \rho(X) + c$ .

A4 **Homogeneidad positiva:** Para todo  $X \in \mathcal{X}$ ,  $\lambda \geq 0$ ,  $\rho(\lambda X) = \lambda \rho(X)$ .

## Ejemplo (Valor esperado)

*Para cada  $X$*

$$\rho(X) = E[X]$$

*es una función de riesgo coherente.*

## No-ejemplo (Value at Risk)



*Para cada  $X$*

$$\rho(X) = V@R_{\alpha}[X] = \inf\{x : P(X > x) \leq \alpha\}$$

**no** es una función de riesgo coherente. Verifica (A2-A4) pero no la convexidad.



# Value at Risk: interpretación

Caso continuo:





# Value at Risk: interpretación

Caso continuo:



Caso discreto:





# Average Value-at-Risk

**Idea:** Definir un valor medio de costo para el  $\alpha\%$  peor de los casos.

Caso continuo:

$$AV@R_\alpha(X) = E[X \mid X > V@R_\alpha(X)] = \frac{1}{\alpha} \int_{V@R_\alpha(X)}^{\infty} xf(x)dx.$$







# Average Value-at-Risk

**Caso discreto:** el problema está en que el cuantil  $\alpha$  no es exacto, es decir en general:

$$P(X > V@R_\alpha(X)) < \alpha, \quad P(X \geq V@R_\alpha(X)) > \alpha.$$

**Idea:** Considerar parte del átomo que se encuentra en el  $V@R_\alpha(X)$  en el cálculo.



## Definición: Average value at risk

Para cada  $X \in \mathcal{X}$  se define:

$$\rho(X) = AV@R_{\alpha}(X) = \inf_x \left\{ x + \frac{1}{\alpha} E[(X - x)^+] \right\}.$$

## Definición: Average value at risk

Para cada  $X \in \mathcal{X}$  se define:

$$\rho(X) = AV@R_\alpha(X) = \inf_x \left\{ x + \frac{1}{\alpha} E[(X - x)^+] \right\}.$$

## Propiedades:

- ▶ Es una medida de riesgo coherente (verifica A1-A4).
- ▶ Es conservadora respecto al  $V@R_\alpha$ , es decir:  $AV@R_\alpha(X) \geq V@R_\alpha(X)$ .

# Average Value-at-Risk

## Caso continuo

En el caso continuo la definición coincide con la que ya vimos. Sea:

$$g(x) = x + \frac{1}{\alpha} E[(X - x)^+]$$

Observando que  $\frac{d}{dx}(X - x)^+ = -\mathbf{1}_{\{X > x\}}$  (ctp), se tiene que:

$$g'(x) = 1 + \frac{1}{\alpha} E[-\mathbf{1}_{\{X > x\}}] = 1 - \frac{1}{\alpha} P(X > x) = 0 \Leftrightarrow x = x^* =: V@R_{\alpha}(X).$$

De donde:

$$\begin{aligned} AV@R_{\alpha}(X) &= x^* + \frac{1}{\alpha} E[(X - x^*)^+] \\ &= \frac{1}{\alpha} E[(x^* + (X - x^*)^+) \mathbf{1}_{\{X \geq x^*\}}] \\ &= \frac{1}{\alpha} E[X \mathbf{1}_{\{X > x^*\}}] = E[X \mid X > V@R_{\alpha}(X)] \end{aligned}$$

# Average Value-at-Risk

## Caso discreto

Sea  $X$  una v.a. discreta con recorrido  $x_1 < \dots < x_n$  y probabilidades  $P(X = x_i) = p_i$ .  
Entonces:

$$g(x) = x + \frac{1}{\alpha} E[(X - x)^+] = x + \frac{1}{\alpha} \sum_{x_i > x} p_i (x_i - x).$$

La anterior es una función lineal a tramos de  $x$ . Nuevamente se tiene:

$$g'(x) = 1 - \frac{1}{\alpha} \sum_{x_i > x} p_i = 1 - \frac{1}{\alpha} \sum_i p_i \mathbf{1}_{\{x_i > x\}}.$$

La función anterior cambia de signo en  $x^* : P(X > x^*) < \alpha$  y  $P(X \geq x^*) \geq \alpha$ , es decir, en  $x^* = V@R_\alpha(x)$ .

# Average Value-at-Risk

## Caso discreto

Evaluando en  $x^*$  obtenemos:

$$\begin{aligned}AV@R_\alpha(X) &= x^* + \frac{1}{\alpha} \sum_{x_i > x^*} p_i(x_i - x^*) \\&= \frac{1}{\alpha} \left[ \alpha x^* + \sum_{x_i > x^*} p_i(x_i - x^*) \right] \\&= \frac{1}{\alpha} \left[ \left( \alpha - \sum_{x_i > x^*} p_i \right) x^* + \sum_{x_i > x^*} p_i x_i \right] \\&= \left( 1 - \sum_{x_i > x^*} \frac{p_i}{\alpha} \right) x^* + \sum_{x_i > x^*} \frac{p_i}{\alpha} x_i\end{aligned}$$

# Average Value-at-Risk

## Caso discreto

Es decir, para calcular el  $AV@R_\alpha(X)$  discreta debemos:



- ▶ Ordenar el recorrido  $x_1 < x_2 < \dots < x_n$ .
- ▶ Hallar  $x^* = V@R_\alpha(X)$  tal que  $P(X > x^*) < \alpha$  y  $P(X \geq x^*) \geq \alpha$ .
- ▶ Reasignar las probabilidades del recorrido como:

$$x_i < x^* \rightarrow 0, \quad x^* \rightarrow \left(1 - \sum_{x_i > x^*} \frac{p_i}{\alpha}\right), \quad x_i > x^* \rightarrow \frac{p_i}{\alpha}.$$

y en este caso  $AV@R_\alpha(X) = E_\alpha[X]$  siendo  $E_\alpha$  la esperanza con la nueva medida de probabilidad.

# Average Value-at-Risk

Caso discreto: ejemplo





Medidas de riesgo

**Programación dinámica de riesgo coherente**

SDDP con medidas de riesgo

Ejemplo

## Problema del costo medio

$$\min_{\pi} E \left[ \sum_{k=0}^{N-1} g_k(x_k, u_k, w_k) + g_N(x_N) \right],$$

$$\text{sujeto a: } x_{k+1} = f_k(x_k, u_k, w_k)$$

$$u_k = \pi_k(x_k, w_k).$$

con la hipótesis de que  $w_k$  son v.a. *iid*.

La esperanza anterior es en todos los  $w_k$  futuros.

## Algoritmo de Bellman para el costo medio

Asumiendo un esquema ruido  $\rightarrow$  decisión:

$$\begin{aligned}V_N(x) &= g_N(x), \\ \hat{V}_k(x, w) &= \min_{u_k} \{g_k(x, u_k, w) + V_{k+1}(f_k(x, u_k, w))\}, \\ V_k(x) &= E \left[ \hat{V}_k(x, w_k) \right]\end{aligned}$$

Política óptima:

$$\pi_k(x, w) = \arg \min_{u_k} \{g_k(x, u_k, w) + V_{k+1}(f_k(x, u_k, w))\}.$$

# Problema de aversión al riesgo

Si ahora tenemos una medida de riesgo  $\rho$  uno podría plantear:

## Problema global de aversión al riesgo

$$\min_{\pi} \rho \left[ \sum_{k=0}^{N-1} g_k(x_k, u_k, w_k) + g_N(x_N) \right],$$

$$\text{sujeto a: } x_{k+1} = f_k(x_k, u_k, w_k)$$

$$u_k = \pi_k(x_k, w_k).$$

con  $w_k$  *iid*.

**Problema:** No es posible descomponer aditivamente  $\rho$ , por lo que la estrategia de Bellman no funciona.

# Problema de aversión al riesgo anidado

Como sustituto del problema anterior, uno puede plantear:

## Problema anidado de aversión al riesgo

$$\min_{u_0} \rho_0 \left[ g_0(x_0, u_0, w_0) + \rho_1 \left[ \min_{u_1} g_1(x_1, u_1, w_1) + \rho_2[\dots] \right] \right]$$

con las restricciones adicionales:

$$x_{k+1} = f_k(x_k, u_k, w_k)$$

y con  $w_k$  iid.

**Nota:** Las medidas de riesgo  $\rho_k$  toman en cuenta la información disponible hasta  $k$  (riesgo condicional al estado  $x_k$  y ruido  $w_k$ ).

# Stochastic dynamic programming con aversión al riesgo

El problema anterior admite una descomposición tipo Bellman:

## Algoritmo de Bellman con aversión al riesgo

Asumiendo un esquema ruido  $\rightarrow$  decisión:

$$\begin{aligned}V_N(x) &= g_N(x), \\ \hat{V}_k(x, w) &= \min_{u_k} \{g_k(x, u_k, w) + V_{k+1}(f_k(x, u_k, w))\}, \\ V_k(x) &= \rho_k \left[ \hat{V}_k(x, w_k) \right]\end{aligned}$$

Política óptima:

$$\pi_k(x, w) = \arg \min_{u_k} \{g_k(x, u_k, w) + V_{k+1}(f_k(x, u_k, w))\}.$$

Medidas de riesgo

Programación dinámica de riesgo coherente

**SDDP con medidas de riesgo**

Ejemplo

# Operador de Bellman para el costo medio

- Para cada  $k$  y una función  $V : \mathcal{X} \times \mathcal{W} \rightarrow \mathbb{R}$  se define:

$$[\hat{T}_k(V)](x, w) := \min_u \{g_k(x, u, w) + V(f(x, u, w))\}.$$

- Con esta notación la iteración de Bellman resulta:

$$\begin{aligned} V_N(x) &= g_N(x), \\ V_k(x) &= T_k(V_{k+1}(x)) := E \left[ \hat{T}(V_{k+1})(x, w_k) \right] \end{aligned}$$

- Este operador es monótono y preserva la convexidad.



## SDDP para el costo medio

- Supongamos que tenemos una cota inferior  $V_{k+1}^{(l+1)} \leq V_{k+1}$  y un estado  $x_k^{(l)}$ . Resolvemos:

$$\begin{aligned} \hat{\beta}_k^{(l+1)}(w) &= \min_{x,u} \left\{ g_k(x, u, w) + V_{k+1}^{(l+1)}(f_k(x, u, w)) \right\}, \\ \text{s.t. } x &= x_k^{(l)} \quad [\hat{\lambda}_k^{(l+1)}(w)]. \end{aligned}$$

- Por lo tanto:

$$\begin{aligned} \hat{\beta}_k^{(l+1)}(w) &= \hat{T}_k(V_{k+1}^{(l+1)})(x_k^{(l)}, w), \\ \hat{\lambda}_k^{(l+1)}(w) &\in \partial_x \hat{T}_k(V_{k+1}^{(l+1)})(x_k^{(l)}, w). \end{aligned}$$

- Para cada perturbación entonces:

$$\hat{\beta}_k^{(l+1)}(w) + (\hat{\lambda}_k^{(l+1)})^T (x - x_k^{(l)}) \leq \hat{T}_k(V_{k+1}^{(l+1)})(x, w) \leq \hat{V}_k(x, w).$$

- Promediando sobre los escenarios, tenemos una cota inferior para la función de valor:

$$\beta_k^{(l+1)} + (\lambda_k^{(l+1)})^T (x - x_k^{(l)}) \leq E(\hat{V}_k(x, w)) = V_k(x).$$

- En cada paso definimos:

$$\begin{aligned}\beta_k^{(l+1)} &= E[\hat{\beta}_k^{(l+1)}(w)] = T_k(V_{k+1}^{(l+1)})(x), \\ \lambda_k^{(l+1)} &= E[\hat{\lambda}_k^{(l+1)}(w)] \in \partial_x T_k(V_{k+1}^{(l+1)})(x).\end{aligned}$$

lo que define un nuevo corte para la aproximación de  $V_k$ .

Supongamos que disponemos de una medida de aversión al riesgo  $\rho(X)$  tal que:

$$\rho(X) = E_P[X]$$

siendo  $P$  una medida de probabilidad adecuada.

► Ejemplos:

►  $\rho(X) = E[X]$ .

►  $\rho(X) = AV@R_\alpha[X] = E_\alpha[X]$  con  $E_\alpha$  como vimos antes.

►  $\rho(X) = \lambda E[X] + (1 - \lambda)AV@R_\alpha[X]$ ,  $\lambda \in [0, 1]$  permite "matizar" la aversión al riesgo.

► ¡Entonces toda la deducción anterior vale cambiando  $E$  por  $E_P$ !

Al comienzo de cada paso: disponemos de una aproximación  $V_k^{(l)}$  de  $V_k$  tal que:

- ▶  $V_k^{(l)} \leq V_k$ .
- ▶  $V_N^{(l)} = g_N$ , el costo terminal.
- ▶  $V_k^{(l)}$  es convexa (mejor aún, lineal a tramos...)

# Algoritmo SDDP

Forward iteration:

- ▶ Seleccionamos un escenario al azar  $w_0, \dots, w_{N-1}$ .
- ▶ Construimos la trayectoria  $x_k^{(l)}$  siguiendo la dinámica:

$$u_k^{(l)} = \arg \min_u \left\{ g_k(x_k^{(l)}, u, w_k) + V_{k+1}^{(l)}(f(x_k^{(l)}, u, w_k)) \right\},$$
$$x_{k+1}^{(l)} = f_k(x_k^{(l)}, u_k^{(l)}, w_k).$$

- ▶ Es decir, la trayectoria calculada como si las funciones de cost-to-go se fueran sus aproximaciones  $V_k^{(l)}$ .

# Algoritmo SDDP

## Backward iteration:

- ▶ En cada  $k$  queremos mejorar la estimación de  $V_k^{(l)}$ .
- ▶ Resolvemos, en cada  $k$ , **para todo posible**  $w$ :

$$\begin{aligned}\hat{\beta}_k^{(l+1)}(w) &= \min_{x,u} \{g_k(x, u, w) + V_{k+1}^{(l+1)}(f_k(x, u, w))\}, \\ \text{s.t. } x &= x_k^{(l)} \quad [\hat{\lambda}_k^{(l+1)}(w)].\end{aligned}$$

- ▶ Con la lista de valores  $\{\hat{\beta}_k^{(l+1)}(w_i), i = 1, \dots, M\}$ , construimos la medida de probabilidad  $P$  que permite calcular  $\rho \left[ \hat{\beta}_k^{(l+1)}(w) \right]$  como una esperanza.

**Ejemplo:** si  $\rho$  es el  $AV@R_\alpha$ , ordenamos los valores de menor a mayor, calculamos el cuantil  $\alpha$  y hacemos la transformación de probabilidades ya vista.

# Algoritmo SDDP

## Backward iteration:

- Calculamos el subgradiente y óptimo promedio:

$$\beta_k^{(l+1)} = E_P[\hat{\beta}_k^{(l+1)}(\mathbf{w})], \quad \lambda_k^{(l+1)} = E_P[\hat{\lambda}_k^{(l+1)}(\mathbf{w})].$$

- Es decir, se promedia utilizando las probabilidades transformadas tanto en  $\beta$  como en  $\lambda$ .
- Agregamos el corte a la estimación:

$$V_k^{(l+1)}(x) = \max\{V_k^{(l)}(x), \beta_k^{(l+1)} + (\lambda_k^{(l+1)})^T(x - x_k^{(l)})\}$$

- Retrocedemos de  $k$  a  $k - 1$  y al llegar a 0 se completa la pasada.

Medidas de riesgo

Programación dinámica de riesgo coherente

SDDP con medidas de riesgo

**Ejemplo**



## Ejemplo: el problema del vendedor de periódicos

Consideremos el siguiente problema:

- ▶ Un vendedor de periódicos debe decidir cuántos reservar. El precio de reserva (el día antes) es  $p$ .
- ▶ El día de venta recibe una demanda de periódicos  $W \sim U[0, \theta]$  (para fijar ideas).
- ▶ Si la demanda supera la reserva, debe comprar periódicos extra a precio  $q > p$ .

Preguntas:

- ▶ ¿Cuánto debemos reservar si queremos minimizar el costo medio?
- ▶ ¿Cuánto debemos reservar si queremos minimizar el  $AV@R_\alpha$  del costo?

# Ejemplo: el problema del vendedor de periódicos

## Formulación como problema de programación dinámica

Tomemos:

- ▶  $x_0 = 0$  el stock inicial.
- ▶  $u_0$  el control (reserva).
- ▶  $g_0(x_0, u_0) = pu_0$ , costo del primer paso.
- ▶  $x_1 = x_0 + u_0$  la dinámica.  $x_1$  es el stock al día siguiente.
- ▶  $g_1(x_1, u_1, w_1) = qu_1$ .
- ▶ Con la restricción adicional de que  $x_2 = x_1 + u_1 - w_1 \geq 0$  (debo cumplir toda la demanda en la segunda compra), además  $u_0 \geq 0, u_1 \geq 0$ .

# Ejemplo: el problema del vendedor de periódicos

## Newsvendor problem, average cost formulation

Hallar:

$$\min_u \{ pu + E[q(W - u)^+] \}$$

con  $W \sim U[0, \theta]$  en este caso.

## Newsvendor problem, risk averse formulation

Hallar:

$$\min_u \{ pu + \rho_\alpha[q(W - u)^+] \}$$

con  $W \sim U[0, \theta]$  en este caso.



**Observación:**  $V(x) = V(u) = E[q(W - x)^+]$  o  $V_\alpha(x) = V_\alpha(u) = \rho_\alpha[q(W - x)^+]$  juegan el rol de función de costo/riesgo futuro.

# Cálculo del costo futuro

Haciendo cuentas con la  $U[0, \theta]$  se llega a:

► Costo medio futuro:

$$E[(W - x)^+] = \frac{(\theta - x)^2}{2\theta}$$





# Cálculo del costo futuro

Nuevamente haciendo cuentas con la  $U[0, \theta]$  se llega a:

► Riesgo medio futuro:

$$\rho_{\alpha} [(W - x)^+] = \begin{cases} \theta \left(1 - \frac{\alpha}{2}\right) - x, & \text{si } x < \theta(1 - \alpha) \\ \frac{(\theta - x)^2}{2\alpha\theta}, & \text{si } x \geq \theta(1 - \alpha) \end{cases}$$





# Cálculo del costo futuro

Nuevamente haciendo cuentas con la  $U[0, \theta]$  se llega a:

► Riesgo medio futuro:

$$\rho_{\alpha} [(W - x)^+] = \begin{cases} \theta \left(1 - \frac{\alpha}{2}\right) - x, & \text{si } x < \theta(1 - \alpha) \\ \frac{(\theta - x)^2}{2\alpha\theta}, & \text{si } x \geq \theta(1 - \alpha) \end{cases}$$



# Solución del problema de costo medio

Debemos hallar:

$$\min_u \{pu + qE[(W - u)^+]\}$$

con  $p < q$ , que corresponde a:

$$\min_u \left\{ pu + q \frac{(\theta - u)^2}{2\theta} \right\}$$

Derivando e igualando a 0, obtenemos:

$$u^* = \theta \left( 1 - \frac{p}{q} \right).$$

# Solución del problema de aversión al riesgo

Debemos hallar:

$$\min_u \{pu + q\rho_\alpha[(W - u)^+]\}$$

con  $p < q$ . Derivando  $q\rho_\alpha$  se tiene que la parte lineal tiene pendiente  $p - q < 0$  por lo que el mínimo se da después de  $\theta(1 - \alpha)$ . Derivando la segunda parte se llega a la condición:

$$p - q \frac{\theta - u}{\alpha\theta} = 0,$$

por lo que la compra óptima es:

$$u^* = \theta \left( 1 - \alpha \frac{p}{q} \right).$$



En cuaderno de Julia adjunto

# Implementación en Julia

- ▶ La biblioteca SDDP.jl permite correr SDDP con aversión al riesgo.
- ▶ Requiere ruidos discretos, y puede considerar el caso de incertidumbre markoviana.
- ▶ Incluye  $AV@R_\alpha$  y una combinación convexa de esperanza y  $AV@R$ .
- ▶ Notar que si  $\alpha \rightarrow 0$  corresponde a optimizar el peor caso, lo que también está incluido.
- ▶ No conlleva una penalidad de performance (misma cantidad de LPs, agrega un sort para construir la medida de probabilidad del  $AV@R$ ).
- ▶ En preparación: cuaderno de Julia con un ejemplo hidrotérmico.

# Muchas gracias!

Contacto: [ferragut@ort.edu.uy](mailto:ferragut@ort.edu.uy)

Código y slides disponibles en: [https://github.com/Grupo-MATE/risk\\_averse\\_sddp](https://github.com/Grupo-MATE/risk_averse_sddp)